

Implementación de KDTree y KNN para clasificación de registros de datos de cardiopatías

Jesús Alpaca Rendón

septiembre 2023

1 Introducción

El presente trabajo es para presentar una implementación de la estructura KDTree donde se insertaran los datos para después ser procesados por K-Neighbors Nearest, esto ayuda a brindar una clasificación a los datos según su posición en el plano cartesiano. El algoritmo procesará en esta ocasión datos de pacientes que fallecieron por causas del corazón, el registro tiene una lista de datos de diferentes características donde indican si el paciente tuvo o no un ataque al corazón. La idea principal es que se realice la experimentación de ver la exactitud que tiene el algoritmo para realizar correctamente la clasificación de datos

2 Problema

Se tiene una base de datos de pacientes que fallecieron por problemas en el corazón, aquí se muestra cuáles fallecieron por un ataque al corazón o como se diría comúnmente, infarto de miocardio y cuáles no. El tamaño del conjunto de datos es de 1319 muestras, que tienen nueve campos, ocho de los cuales son de entrada y uno de salida. La edad, el sexo (0 para mujer y 1 para hombre), la frecuencia cardíaca (impulso), la PA sistólica (presión alta), la PA diastólica (presión baja), la glucemia (glucosa), la CK-MB (kcm) y la troponina (troponina) representan los campos de entrada, mientras que el campo de salida corresponde a la presencia de infarto de

miocardio (clase), que se divide en dos categorías (negativa y positiva); la negativa se refiere a la ausencia de infarto de miocardio, mientras que la positiva se refiere a la presencia de infarto de miocardio. Se requiere tener un modelo que nos permita clasificar otros pacientes que puedan añadirse al registro de forma automática. El dataset seleccionado se denomina "Heart Disease Classification Dataset", el cual se pudo verificar que con algoritmos de las librerías de python basadas en KNN, se obtuvo un accuracy de 60 - 63 por ciento, siendo otros algoritmos más eficaces, sin embargo para el presente proyecto se realizó una implementación propia basada en el pseudocódigo de KDtree y KNN.

3 Implementación

Para la implementación se utilizó el lenguaje Python y la fuente de datos de Kaggle "Heart Disease Classification Dataset". Adicionalmente se utilizaron librerías de python para la impresión de los gráficos y el cálculo de las métricas de medición de los tests. El link del repositorio es el siguiente:

- [Repositorio Jesus Alpaca Rendon Ejercicio Final KDTree](#)

4 Resultados

La implementación ingresa los datos del dataset a la estructura del KDTree, después de ello, se aplica el KNN para encontrar los vecinos. Para hacer la prueba correctamente, se obtuvo una serie de datos de test y datos de entrenamiento a partir del dataset principal para ejecutarlo acorde a lo implementado. El dataset contiene 1319 muestras de las cuales se utilizó la siguiente cantidad de datos para el entrenamiento y pruebas:

```
Shape of X_Train set : (989, 8)
Shape of y_Train set : (989,)

-----
Shape of X_test set : (330, 8)
Shape of y_test set : (330,)
```

Figure 1: Datos de Entrenamiento y Test

Se utilizó un total de 989 registros del dataset para entrenar la muestra y se utilizó 330 test para obtener 5 vecinos cercanos para cada uno, dando la clasificación a partir de la mayor cantidad de tipos de vecinos cercanos hallados. Es decir, si 3 de 2 vecinos no tuvieron un ataque cardiaco, se clasifica con 0, que representa los pacientes que no tuvieron ningún tipo de ataque, y en caso contrario, se le marcara con 1.

Al ejecutar la implementación, se muestra la clasificación de data correcta y las predicciones que halló el sistema:

La matriz de comparación quedaría de la siguiente manera:

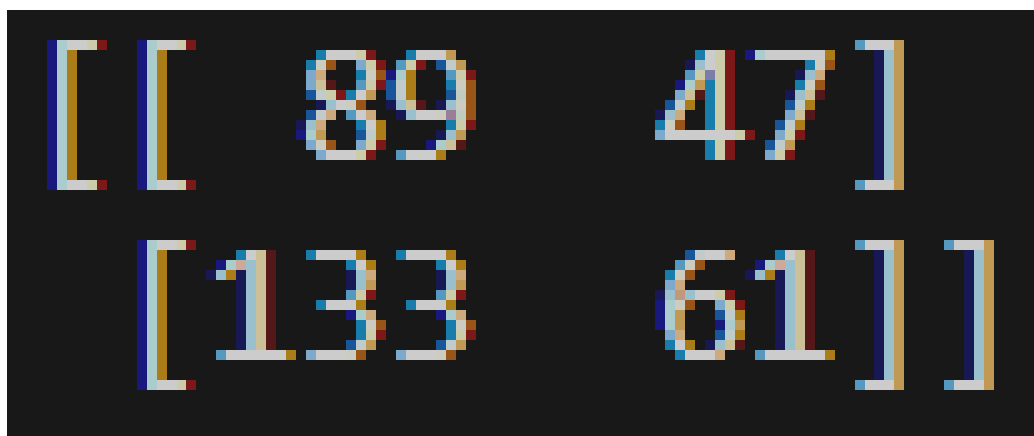


Figure 2: Matriz de comparación del test

Siendo el mismo orden con el que se representa la matriz en la teoría:

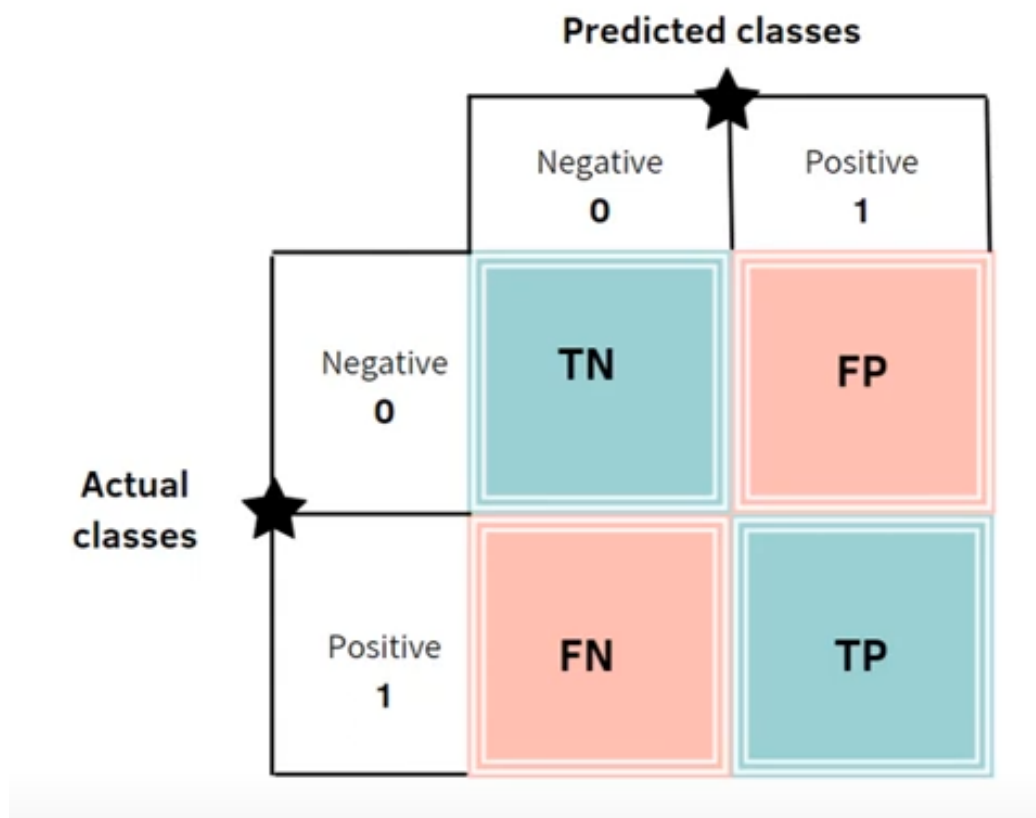


Figure 3: Matriz de comparación según la teoría

A partir de la tabla podemos empezar a sacar las métricas que nos indican cuanta precisión tendría nuestro modelo para clasificar:

	precision	recall	f1-score	support
0	0.40	0.65	0.50	136
1	0.56	0.31	0.40	194
accuracy			0.45	330
macro avg	0.48	0.48	0.45	330
weighted avg	0.50	0.45	0.44	330

Figure 4: Matriz de precisión de clasificación

Como se puede observar, se tiene una precisión promedio de 0.45 - 0.55, la cual está un poco alejada de la precisión que tiene la implementación actual que tiene Python en su librería. Podemos realizar una comparativa rápida con los resultados obtenidos por el mismo algoritmo de Python, obteniendo estos resultados.

	precision	recall	f1-score	support
0	0.55	0.46	0.50	136
1	0.66	0.74	0.70	194
accuracy			0.62	330
macro avg	0.61	0.60	0.60	330
weighted avg	0.62	0.62	0.62	330

Figure 5: Matriz de precisión de clasificación de la librería de Python KNN

Como podemos observar, la precisión promedio es de 0.60 - 0.65 lo cual supera la precisión de la implementación desarrollada.

Podemos verificar uno de los resultados en los gráficos, como se indicó se tendría una gran cantidad de datos para el aprendizaje, por lo que se encontrarán varios puntos en la gráfica.




Figure 6: Gráfica de todos los puntos de training

Si nos acercamos más, podemos ver que el punto a clasificar, en este caso el punto azul, tiene 3 puntos amarillos, los cuales son de estado 0 y 2 morados de estado 1, dando como resultado la clasificación a 0. Si revisamos los resultados mostrados en la figura 2, veremos que la predicción fue correcta.




Figure 7: Clasificación del punto inicial de test

5 Conclusiones

Como conclusiones se puede indicar lo siguiente:

- La implementación de KDTree para la resolución del problema es una investigación que denota interés, ya que es una de las estructuras multidimensionales más completas.
- Se debe considerar que la precisión obtenida no es muy aceptable ya que con mucho esfuerzo logra pasar el 50% de precisión, KNN no sería un algoritmo idóneo para clasificar datos.
- Existen otros algoritmos más fuertes que pueden aplicar una precisión

mas aceptable, lo cual se recomienda realizar un proceso similar con otros algoritmos.

References

- [1] Steinbach, Michael and Tan Pang-Ning. *The Top Ten Algorithms in Data Mining*. University of Minnesota Twin Cities, 1st Edition chapter 8, 2009.
- [2] Ching (Chingis). KNN-python-implementation. URL: <https://chingisoinar.medium.com/>
- [3] M.C. Edgar Moyete (Moyete) - Canal de Machine Learning. URL: <https://www.youtube.com/@Moyetepython>